

Auditoria Técnica Senex AI

v5.1.0

Auto-Auditoria Técnica e Regulatória — Documento Executivo + Técnico Completo

Lovable Agent · Equipe PetMoreTime

31 de maio de 2026

- [Auditoria Técnica Senex AI v5.1.0](#)
 - [Sumário](#)
 - [1. Sumário Executivo](#)
 - [2. Glossário e convenções](#)
 - [3. Metodologia da auto-auditoria](#)
 - [4. Visão arquitetural — 5 camadas Senex AI](#)
 - [5. Pipeline de digestão de estudos \(7 estágios\)](#)
 - [6. Vetorização e embeddings](#)
 - [7. Banco de dados relacional e RLS](#)
 - [8. Uso de LLM — onde, como, quais modelos](#)
 - [9. Knowledge Graph \(Supabase espelho + Neo4j\)](#)
 - [10. Análise do paciente — 6 estágios](#)
 - [11. Sistema de recomendação híbrida](#)
 - [12. Gêmeo Digital — projeção sigmoidal de desfechos](#)
 - [13. Jornada real do revisor veterinário](#)
 - [14. Jornada prevista do revisor \(roadmap\)](#)
 - [15. Jornada real do estudo científico](#)
 - [16. Jornada prevista do estudo \(roadmap\)](#)
 - [17. Comparação MedGraphRAG × VetGraphRAG v2 × Senex AI v5.1.0](#)
 - [18. Conformidade FDA — matriz ponto-a-ponto](#)
 - [19. Conformidade EMA + EU AI Act](#)
 - [20. Conformidade AVMA / AAVSB](#)
 - [21. GMLP — análise por princípio](#)
 - [22. Pontos fortes \(18\)](#)
 - [23. Pontos fracos, gaps e riscos \(12 + 5\)](#)

- [24. Roadmap P0-P3 detalhado](#)
- [25. Apêndice A — Schema SQL principal \(DDL real, abreviado\)](#)
- [26. Apêndice B — Inventário de Edge Functions \(67 deployadas\)](#)
- [27. Apêndice C — Prompts e modelos LLM \(snapshot 8 ativos\)](#)
- [28. Apêndice D — Métricas operacionais \(snapshot 31/05/2026\)](#)
- [29. Bibliografia \(rodapés \[1\]-\[14\]\)](#)

Auditoria Técnica Senex AI v5.1.0

Versão 5.1.0 · Documento Executivo + Técnico Completo · ~30 páginas

Pipeline · Vetorização · LLM · Knowledge Graph · Recomendação Híbrida · Gêmeo Digital · Gap-Fill PubMed

Mapeamento ponto-a-ponto **FDA Jan/2025 · EMA Set/2024 · EU AI Act · AVMA Nov/2025 · GMLP**

Estado-da-arte 2025-2026 · 10 infográficos · 14 referências verificáveis · Sucessora direta da auditoria v3 (10/05/2026)

Escopo: canino, condições metabólicas e degenerativas, geroproteção

Sumário

1. Sumário Executivo
2. Glossário e convenções
3. Metodologia da auto-auditoria
4. Visão arquitetural — 5 camadas Senex AI
5. Pipeline de digestão de estudos (7 estágios)
6. Vetorização e embeddings
7. Banco de dados relacional e RLS
8. Uso de LLM — onde, como, quais modelos
9. Knowledge Graph (Supabase espelho + Neo4j)
10. Análise do paciente — 6 estágios
11. Sistema de recomendação híbrida
12. Gêmeo Digital — projeção sigmoidal de desfechos
13. Jornada real do revisor veterinário

14. Jornada prevista do revisor (roadmap)
15. Jornada real do estudo científico
16. Jornada prevista do estudo (roadmap)
17. Comparação MedGraphRAG × VetGraphRAG v2 × Senex AI
18. Conformidade FDA — matriz ponto-a-ponto
19. Conformidade EMA + EU AI Act
20. Conformidade AVMA / AAVSB
21. GMLP — análise por princípio
22. Pontos fortes (18)
23. Pontos fracos, gaps e riscos (12 + 5)
24. Roadmap P0-P3 detalhado
25. Apêndice A — Schema SQL principal
26. Apêndice B — Inventário de Edge Functions (67)
27. Apêndice C — Prompts e modelos LLM
28. Apêndice D — Métricas operacionais (snapshot 31/05/2026)
29. Bibliografia (rodapés [1]–[14])

1. Sumário Executivo

A **Senex AI** (motor sucessor de VetGraphRAG, marca exclusiva PetMoreTime desde 2025) é uma plataforma veterinária de apoio à decisão clínica que combina **Retrieval-Augmented Generation** sobre um **Knowledge Graph causal de cinco camadas** (Composto → Alvo → Mecanismo → Efeito → Desfecho) com curadoria humana obrigatória, projeções de gêmeo digital e governança bilíngue PT/EN aplicada em todas as camadas — UI, banco e dados estáticos. O modelo conceitual é inspirado no MedGraphRAG¹ (Wu et al., Oxford 2024) e na literatura GraphRAG da Microsoft Research², adaptados ao domínio veterinário canino com foco exclusivo em condições metabólicas e degenerativas, e estendidos com (a) política de no-mock estrita, (b) gatekeeper de curadoria pré-publicação, (c) gap-fill automático PubMed + Gemini, e (d) Digital Twin sigmoidal calibrado em Gompertz por raça.

Esta auto-auditoria v5.1.0 substitui a versão pobre gerada em 18/05 e, em paridade qualitativa com a v3 (10/05), incorpora as evoluções consolidadas entre 11/05 e 31/05: (i) reorganização das tabs administrativas em sidebar persistente com Governança & IA no topo, (ii) adoção do roteador universal `ai-task-router` com `ai_prompt_versions` versionadas e `ai_task_invocations` auditáveis, (iii) introdução do `kg-evidence-gap-fill` como pipeline admin que fecha lacunas (composto × condição) via

PubMed E-utilities + Gemini, (iv) ampliação da matriz de Pontos Fortes para 18 itens (todos com evidência de código/arquivo), (v) detalhamento de 12 gaps com prioridade P0-P3 e mitigação, e (vi) consolidação do conceito de **Patient Knowledge Subgraph** como único artefato apresentado ao veterinário (corte determinístico do KG por paciente).


Métricas operacionais vivas (snapshot 31/05/2026): 13 estudos científicos catalogados · 59 processados via pipeline · 1.342 chunks vetorizados em 44 estudos · **4.785 triplets extraídos** dos quais **3.924 aprovados e 4.411 sincronizados** ao espelho gráfico · 38.643 arestas hierárquicas · 191 condições de saúde curadas · 30 nutracêuticos · 254 predisposições raciais · 668 perfis de pacientes (5 demo) · 8 prompts ativos versionados · 28 invocações IA auditadas · 941 nós de ontologia veterinária · 18 core rules.

Os **pontos fortes mais relevantes** são (a) ausência absoluta de mock data clínico — toda recomendação é rastreável até estudo + triplet aprovado + edge real; (b) bilinguismo PT/EN aplicado em todas as camadas com versionamento por `I18N_VERSION` para invalidação de cache; (c) auditabilidade completa via `study_audit_logs`, `ClinicalPipelineLogPanel`, `DigitalTwinLogPanel`, `EvidenceGapLogPanel` e o novo `ai_task_invocations`; (d) human-in-the-loop conforme Art. 14 do EU AI Act, com `has_role()` segurança-definidora; (e) uso de taxonomias autoritativas SNOMED-CT VetSCT e UMLS; (f) políticas RLS exaustivas em 97 tabelas Supabase; e (g) gap-fill automático que materializa novas hipóteses de evidência diretamente da literatura PubMed quando o Digital Twin sinaliza `years_gained` baixo.

Os **principais gaps identificados** — todos rastreados no roadmap — são (a) ausência de Real-World Performance Monitoring longitudinal pós-deploy [P0, FDA Jan/2025 §VII]; (b) base knowledge L1-L3 ainda parcialmente populada por extração automática em vez de ontologia manual [P0]; (c) ausência de validação cruzada entre espécies — o sistema é canino-only, mas o KG não bloqueia tecnicamente a extrapolação [P0, AVMA §3.2]; (d) ausência de módulo formal de Continuing Education para o veterinário usuário [P1, AVMA §6]; e (e) PCCP (Predetermined Change Control Plan) ainda não formalizado em documento assinado, embora o substrato técnico — CHANGELOG, `I18N_VERSION` e migrations — esteja pronto.

O documento abre com a visão arquitetural, percorre os componentes técnicos em profundidade, mapeia conformidade regulatória requisito a requisito (17 entradas), apresenta as jornadas reais e desejadas dos atores humanos e dos artefatos científicos, e encerra com quatro apêndices: schema SQL real,

inventário de 67 Edge Functions deployadas, prompts/modelos LLM ativos e métricas operacionais.



Visão geral do mapa de conformidade regulatória

Figura 1 – Mapa de conformidade FDA × EMA × AVMA × GMLP × pilares Senex.

2. Glossário e convenções

Para garantir leitura consistente entre os perfis executivo, técnico e regulatório, adotamos as seguintes convenções terminológicas em todo o documento:

Termo	Definição operacional no projeto
Composto	Substância ativa simples (curcumina, NMN, resveratrol, ômega-3, S-adenosilmetionina). Camada L0.
Composição nutracêutica	Combinação sinérgica de 2 ou mais compostos (ex.: NMN + TMG). Cap máximo de 8 por stack.
Triplet / Triplo	Asserção causal extraída de literatura no formato (sujeito, predicado, objeto) com nível de evidência, intensidade e fonte.

Termo	Definição operacional no projeto
Base entity	Nó manualmente curado e canonicalizado contra SNOMED-VetSCT/UMLS. Distinto de extracted entity (provém apenas de PDF).
Curation gatekeeper	Princípio: nenhum triplet entra no KG de produção sem (a) aprovação manual ou (b) confidence ≥ 0.50 (auto-approve documentado).
Patient Knowledge Subgraph	Recorte determinístico do KG contendo apenas nós e arestas que sustentam a recomendação ativa para um paciente específico.
I18N_VERSION	Constante em <code>src/i18n.ts</code> incrementada a cada mudança em strings bilíngues; força bust de cache do navegador (snapshot atual: 1.86.7).
Digital Twin	Modelo sigmoidal (Gompertz por raça) que projeta evolução de severidade clínica em função do stack proposto e da evidência KG.
years_gained	Métrica de longevidade adicional projetada pelo Digital Twin, derivada de $\text{evidence_level} \times \text{synergy} \times \text{adesão} \times \text{breed_curve}$.
RWPM	Real-World Performance Monitoring — monitoramento longitudinal de desfecho pós-deploy (FDA).
PCCP	Predetermined Change Control Plan — plano antecipado de mudanças aceitas pela FDA sem nova submissão.
GMLP	Good Machine Learning Practice — 10 princípios FDA/HC/MHRA (2021).
RLS	Row-Level Security — política de acesso por linha no Postgres/Supabase.

Termo	Definição operacional no projeto
Gap-Fill	Pipeline admin (<code>kg-evidence-gap-fill</code>) que detecta lacunas (composto × condição) e materializa triplets candidatos via PubMed + Gemini.

Notação biológica em diagramas: ⊕ ativa · ⊖ inibe · ↑ aumenta · ↓ reduz · ↔ modula · × contraindica · ⇨ sinergia.

Cores semânticas seguem o design system: primário `#1E3A5F`, accent `#3B82F6`, sucesso `#10B981`, alerta `#F59E0B`, erro `#EF4444` — todas definidas em `src/index.css` como tokens HSL.

3. Metodologia da auto-auditoria

A auditoria foi conduzida em quatro frentes paralelas, todas restritas ao código-fonte real do repositório, ao schema vivo do banco Lovable Cloud (Supabase) e às edge functions atualmente deployadas — sem qualquer simulação ou estimativa fora do que está em produção.

3.1 Inspeção de código

Leitura direta de `src/`, `supabase/functions/`, `supabase/migrations/` e `scripts/`. Mapeamento de imports, hooks (`src/hooks/`), serviços (`src/services/`) e componentes administrativos (`src/components/administrador/`). Toda referência a tabela ou função no relatório corresponde a um arquivo verificável.

3.2 Inspeção de dados

Queries `read_query` diretas ao banco produção (PostgREST + RLS) coletando contagens vivas em 31/05/2026. As métricas reportadas em §1 e §28 não são estimadas — vêm de `SELECT COUNT(*)` reais.

3.3 Benchmark documental 2025–2026

- FDA Draft Guidance — “Considerations for the Use of Artificial Intelligence to Support Regulatory Decision-Making for Drug and Biological Products” (Jan/2025)³


- EMA Reflection Paper on Artificial Intelligence (Set/2024)⁴ e EU AI Act (Reg. 2024/1689)⁵
- AVMA Framework on AI in Veterinary Medicine (Nov/2025)⁶
- GMLP — 10 Guiding Principles (FDA/Health Canada/MHRA, 2021)⁷
- AAVSB Position Statement (2025)⁸

3.4 Limitações da auditoria

Esta é uma **auto-auditoria** (first-party) e não substitui auditoria independente de terceiros — recomendada como item P1 antes de qualquer pleito formal junto a corpos regulatórios. Métricas de eficácia clínica reportadas pelo Digital Twin são projeções in-silico baseadas no KG e na literatura indexada; **não há ainda dados de desfecho real coletados longitudinalmente em coorte** (gap P0, ver §24).

4. Visão arquitetural – 5 camadas Senex AI

A ontologia Senex AI é estruturada em cinco camadas causais que conectam intervenção a desfecho clínico. Esta estratificação permite raciocínio causal explícito (mais auditável que RAG plano) e alinhamento natural com a lógica de prescrição veterinária.



Pirâmide invertida das 5 camadas

Figura 2 – Pirâmide invertida das 5 camadas (L0 Composto → L4 Desfecho), com contagens reais do banco.

Camada	Tipo de nó	Exemplos	Origem preferencial	Contagem snapshot
L0	Composto	Curcumina, NMN, Resveratrol, EPA/DHA, SAME	Base entity manual + DrugLookup	30 nutracêuticos + 50 drug_substances
L1	Alvo molecular	SIRT1, NF-κB, Nrf2, COX-2, mTOR	Base entity manual + UMLS	~140 nós (parcial — gap P0)
L2	Mecanismo	Inibição NLRP3, ativação AMPK, redução TNF-α	Extração Stage 2 + curadoria	~480 nós
L3	Efeito biológico	↓ inflamação sistêmica, ↑ autofagia, ↑ sensibilidade insulina	Extração Stage 2 + curadoria	~340 nós
L4	Desfecho clínico	Redução de dor articular, melhora cognitiva, controle glicêmico	health_conditions (manual)	191 condições curadas


O KG vive em **dois substratos sincronizados**: (i) o **Supabase**

(triplet_extractions + hierarchical_edges + medical_knowledge_graph/edges) é a fonte de verdade transacional; (ii) o **Neo4j** é o espelho de consulta otimizado para travessia de grafo (visualização 3D via react-force-graph-3d em WebGL).

Sincronização é unidirecional Supabase → Neo4j via sync-approved-triplets + sync-

ontology-to-neo4j . Apenas triplets com `curation_status='approved'` (ou auto-aprovados por `confidence ≥ 0.50`) cruzam essa fronteira.

5. Pipeline de digestão de estudos (7 estágios)



Pipeline 7 estágios

Figura 3 – Pipeline determinístico de digestão de estudos científicos. Cada estágio escreve em tabela própria com `study_audit_logs` correspondente.

- 1. Upload & Dedup (PDF SHA-256)** — `scientific_studies` recebe metadados; hash SHA-256 do PDF + Levenshtein no título bloqueiam duplicatas antes de qualquer custo de processamento. Tabela `processed_studies` registra o veredicto.
- 2. Parse & Chunking semântico** — `parse-study` extrai texto; chunking semântico (~800 tokens com overlap 100) gera unidades para vetorização.
- 3. Vetorização (text-embedding-004, 768d)** — `vectorize-study` materializa `study_embeddings` (1.342 chunks em 44 estudos no snapshot). Pré-requisito para qualquer curadoria (curador precisa do “Trecho de Origem”).
- 4. Extração Stage 1 – entidades** — `extract-study-entities` (Gemini Flash) identifica compostos, condições, alvos, mecanismos com confidence individual e `source_chunk_id`.
- 5. Extração Stage 2 – relações** — `generate-triplets` (Gemini Pro / GPT-5) emite triplets causais (s, p, o) com `evidence_level`, `intensity`, `species`, `breed`. Validação por dicionário de predicados (`predicate_mapping`) normaliza variações.

6. Enriquecimento & QA — `enrich-triplet` + `enrichment-qa-sample` validam contra `taxonomy_dictionaries` (8 dicionários ativos), atribuem `evidence_level`, detectam contradições contra `evidence_conflicts`.

7. Curadoria & Sync — humano aprova em `TripletCurationTab`; auto-approve para confidence ≥ 0.50 (`reset_neo4j_sync_on_status_change` trigger). `sync-approved-triplets` materializa em `hierarchical_edges`; `sync-study-to-neo4j` espelha no grafo.

Visibilidade Kanban: o filtro garante que a fila de curadoria mostra apenas documentos com `processed_studies.status='completed'` (regra “Kanban Visibility Logic” da memória). Estudos não vetorizados ficam ocultos do curador.

6. Vetorização e embeddings

A vetorização é **pré-requisito da curadoria** — não uma etapa final opcional. Esse princípio está codificado em `extract-study-entities`: o disparo de `vectorize-study` é centralizado via `EdgeRuntime.waitUntil` antes de qualquer Stage 1, garantindo que o curador sempre tenha o “Trecho de Origem” disponível para cada triplet.

Configuração atual: - Modelo: `text-embedding-004` (Google, 768 dimensões) -

Estratégia: chunking semântico ~800 tokens, overlap 100 tokens -

Armazenamento: `study_embeddings` (`chunk_text`, `embedding vector(768)`, `chunk_index`, `chunk_metadata jsonb`) - Índice: HNSW via `pgvector` (`embedding <=> query`) - RPC pública: `search_study_chunks(query_embedding, match_study_id, match_threshold=0.7, match_count=5)`

Snapshot: 1.342 chunks em 44 estudos (média 30,5 chunks/estudo). Estudos ainda não vetorizados (13 catalogados – 44 com embeddings?). *Nota:* o delta de 15 estudos catalogados sem embeddings refere-se a artigos importados antes da política atual, listados no painel “Estudos sem embeddings” da aba Vetorização — gap P2 do roadmap.

RAG híbrido: queries do veterinário (`chat` , `document-chat` , `graph-rag-search`) combinam similarity vetorial com travessia de KG via `hybrid-recommendation`. A combinação retorna evidência ranqueada por proximidade semântica e por nível de evidência do triplet.

7. Banco de dados relacional e RLS


O banco vive em **Lovable Cloud (Supabase, Postgres 15)** com 97 tabelas em `public`. Toda tabela com dados clínicos ou de governança implementa RLS estrita. Roles são armazenadas em tabela dedicada `user_roles` (nunca em `profiles`) e checadas via função `security-definer` `public.has_role(_user_id, _role) / public.is_admin()` — padrão consagrado para evitar recursão de RLS.

7.1 Tabelas críticas (snapshot)

Tabela	Função	Linhas (snapshot)	RLS
<code>scientific_studies</code>	catálogo de PDFs científicos	13	sim
<code>study_embeddings</code>	chunks vetorizados (pgvector 768d)	1.342	sim
<code>triplet_extractions</code>	triplets (s,p,o) extraídos	4.785 (3.924 aprov.)	sim
<code>hierarchical_edges</code>	arestas materializadas do KG	38.643	sim
<code>health_conditions</code>	ontologia clínica canina	191	sim
<code>nutraceuticals</code>	compostos L0 curados	30	sim
<code>breed_predispositions</code>	risco genético por raça	254 (81 raças)	sim
<code>pet_profiles</code>	pacientes (5 demo + 663 reais/sintéticos)	668	sim
<code>ai_prompt_versions</code>	versionamento de prompts	8 (8 ativos)	sim
<code>ai_task_invocations</code>	auditoria de chamadas IA	28	sim
<code>audit_requests</code>	solicitações de auditoria técnica	3 (1 pendente)	sim

Tabela	Função	Linhas (snapshot)	RLS
<code>technical_audits</code>	relatórios de auditoria gerados	2 (v3, v5.1.0)	sim
<code>user_roles</code>	mapping user x app_role	6	sim
<code>core_rules</code>	regras clínicas globais auditáveis	18	sim

7.2 Princípio RLS



Governança & RLS

Figura 4 – Modelo de RLS: separação `user_roles` + função `security-definer` + `policies` por escopo.

```
CREATE OR REPLACE FUNCTION public
boolean
DEFINER SET = public
AS SELECT EXISTS SELECT 1 FROM public
WHERE = AND role =
```

Todo `CREATE TABLE public.*` é seguido por `GRANT` explícito + `ALTER TABLE ... ENABLE ROW LEVEL SECURITY` + `policies`. `PostgREST` não concede default ao schema `public`; sem `GRANT` a Data API retorna `permission denied`.

8. Uso de LLM – onde, como, quais modelos

Todas as chamadas IA passam pelo `ai-task-router` (`supabase/functions/_shared/ai-task-router.ts`), o roteador universal introduzido na Fase 2.5 de governança. Para cada `task_id` ele resolve: 1. Modelo ativo (override em `ai_configurations.ai_model_<task_id>` ou recomendado estático). 2. Prompt ativo em `ai_prompt_versions` (versão `is_active=true`). 3. Parâmetros de routing (`reasoning_effort` , `temperature` , `context_caching`).

Toda invocação é registrada em `ai_task_invocations` (latência, tokens in/out, custo estimado, `prompt_version_id` , `caller_function`) e atualiza `ai_task_status` (`ok` , `last_error` , `last_model_id`). Cache in-memory de 30 s reduz reads no DB sem comprometer auditabilidade.

8.1 Mapeamento modelo × tarefa (snapshot)

Task	Modelo padrão	Caller
<code>extract_entities</code>	<code>google/gemini-2.5-flash</code>	<code>extract-study-entities</code>
<code>generate_triplets</code>	<code>google/gemini-2.5-pro</code>	<code>generate-triplets</code>
<code>enrich_triplet</code>	<code>google/gemini-2.5-flash</code>	<code>enrich-triplet</code>
<code>chat_clinical</code>	<code>google/gemini-3-flash-preview</code>	<code>chat</code> , <code>document-chat</code>
<code>gap_fill</code>	<code>openai/gpt-5-mini</code>	<code>kg-evidence-gap-fill</code>
<code>classify_entity</code>	<code>google/gemini-2.5-flash-lite</code>	<code>classify-entity</code>
<code>relations_auditor</code>	<code>google/gemini-2.5-pro</code>	<code>relations-auditor</code>
<code>digital_twin_project</code>	<code>google/gemini-2.5-flash</code>	<code>project-pet-trajectory</code>

Custo estimado (`COST_PER_1K` em `ai-task-router.ts`): Gemini Flash \$0,0003/\$0,0012 in/out; Gemini Pro \$0,00125/\$0,005; GPT-5-mini \$0,0015/0,006.28 *invocações no snapshot — custo total acumulado < US 0,50.*

8.2 Princípios de uso

- **Nenhum prompt clínico hardcoded** — todos vivem em `ai_prompt_versions` com `is_active` único por (task, model) e ativação via `activate_ai_prompt_version()` .
- **Reasoning explícito** quando a tarefa pede (`generate_triplets` , `relations_auditor` usam `effort=medium/high`).

- **Sem reuso de input clínico em treino** — Gemini API explicita não-treinamento em planos pagos.
-

9. Knowledge Graph (Supabase espelho + Neo4j)

O KG Senex vive em dois substratos. O **Supabase** é a fonte de verdade transacional (`triplet_extractions` + `hierarchical_edges`); o **Neo4j** é o espelho de consulta otimizado para travessia, alimentando a visualização 3D interativa via `react-force-graph-3d` (WebGL, escala milhares de nós sem perda de FPS).

Sincronização Supabase → Neo4j: - `sync-approved-triplets` espelha triplets aprovados como arestas (`MERGE (s)-[r:RELATES {predicate, evidence_level, intensity, source_study_id}]->(o)`). - `sync-ontology-to-neo4j` espelha base entities (compostos, alvos, condições) com `snake_case` enforcement. - `sync-study-to-neo4j` materializa o nó do estudo + edges de provenance (`(study)-[:EVIDENCE_FOR]->(triplet)`).

IDs canônicos seguem regra do projeto: sempre o `id UUID` do Supabase (`node.properties.id`), nunca o `elementId` interno do Neo4j — isso garante links estáveis entre UI/DB/grafos e permite navegação cruzada (Patient → Triplet → Estudo → Chunk).

Estatísticas do snapshot: - 38.643 arestas hierárquicas (`hierarchical_edges`) - 4.411 triplets sincronizados ao espelho (de 3.924 aprovados — diferença = sincronizações históricas anteriores ao gate) - 191 condições + 30 nutracêuticos + 941 nós de ontologia veterinária canônica

Patient Knowledge Subgraph: para cada paciente, a UI veterinária mostra **apenas** o recorte do KG que sustenta a recomendação ativa (`patient_id` → `triplets` → `edges` → `compostos`). Isso evita confusão visual com o grafo global de 38k arestas e torna cada recomendação auditável em um clique.


10. Análise do paciente – 6 estágios

O `deep-diagnostic-pipeline` é executado por `extract-pet-clinical-data` + `condition-insights` + `project-pet-trajectory` , em seis estágios encadeados:

1. **Anamnese estruturada** — `pet_profiles` + `pet_consultations` + `pet_conditions`
(origem: Diagnóstico, Exame ou Raça — badges separados na UI por regra “Condition Origin Badges”).
2. **Predisposição racial** — match contra `breed_predispositions` (254 entradas em 81 raças). Aciona alertas preventivos antes de qualquer sintoma.
3. **Interpretação laboratorial** — `pet_exams` flags anormais contra `lab_reference_ranges` (31 ranges caninos). Sinaliza recomendações hepatoprotetoras / renais.
4. **Cruzamento clínico** — `clinical-discovery-cross-reference-analysis` correlaciona anomalias entre labs, medicações ativas (`pet_medications`) e condições.
5. **Projeção de trajetória** — `project-pet-trajectory` (Digital Twin, ver §12) projeta severidade vs cenários com/sem stack.
6. **Recomendação híbrida** — `hybrid-recommendation` propõe stack ≤ 8 compostos sinérgicos (cap rígido, dedupe alfanumérico).

A UI agrega tudo em painéis tabbed por princípio “Tabbed Clinical Analysis” (Diagnóstico · Exames · Predisposições · Inferências · Projeção · Stack) — cada um com chat especializado (`document-chat`) com contexto restrito ao painel.

11. Sistema de recomendação híbrida



Recomendação híbrida


Figura 5 – Edge function `hybrid-recommendation` integra contexto clínico completo do pet ao KG.

A função `hybrid-recommendation` recebe `pet_id` + contexto clínico (condições ativas, exames, medicações, raça) e produz um stack rigorosamente bounded:

- **Cap absoluto de 8 compostos** — qualquer estouro é dedupado por chave alfanumérica do composto.
- **Sinergia obrigatória** — pares (NMN+TMG, EPA+DHA, Curcumina+Piperina) priorizados via `synergy-scoring`.
- **Contraindicações duras** — `contraindications-scoring` rejeita pares antes da entrega (ex.: warfarina + ômega-3 alta dose em paciente com risco hemorrágico).
- **Nomenclatura humana** — labels técnicos (`s_adenosylmethionine`) são traduzidos para apresentação (“SAmE”) via `clinical-name-canonicalizer`.
- **Transparência**: qualquer recomendação sem suporte raw no grafo é **conspicuamente flagada** na UI (princípio “Clinical Recommendation Transparency”).

A função roteia LLM via `ai-task-router` para gerar a justificativa textual + lista, e devolve em paralelo o **Patient Knowledge Subgraph** que sustenta cada item — clicável em cada composto para drilldown até o triplet/estudo de origem.

12. Gêmeo Digital – projeção sigmoidal de desfechos



Digital Twin

Figura 6 – Curva sigmoidal calibrada em Gompertz por raça (`breed_aging_curves`), com cenários com/sem stack.

O Digital Twin (`project-pet-trajectory` + `condition_response_curves`) projeta a evolução de severidade clínica em janelas de 6/12/24 meses para cada condição ativa, usando:

- **Curva basal:** Gompertz por raça (`breed_aging_curves`) parametrizada por massa, expectativa-de-vida-mediana e curva de envelhecimento da raça.
- **Modulação por stack:** cada composto recomendado aplica um delta sigmoidal proporcional a `evidence_level × synergy × adesão` .
- **Output clínico:** `years_gained` (longevidade adicional projetada), `severity_at_12m` , `confidence_interval` .

12.1 Limitações honestas

- Projeções são **in-silico** — não há ainda dados de desfecho real coletados longitudinalmente em coorte de produção (gap P0).
- Calibragem das curvas Gompertz por raça é parcial (53 raças com `breed_aging_curves` válidas, das 81 catalogadas).
- `years_gained < 0,3` aciona automaticamente o gap-fill (§13) para reforço de evidência.

12.2 Trigger para gap-fill

Quando o Twin retorna `years_gained` abaixo do limiar, o painel admin sinaliza a tupla (composto × condição) como candidata a investigação. O operador admin dispara `kg-evidence-gap-fill` (descrito a seguir) e o resultado popula `triplet_extractions` em estado `pending` para curadoria.

13. Jornada real do revisor veterinário

Hoje, o veterinário usuário: 1. Faz login (`AuthPage`) → role `vet` em `user_roles` . 2. Cria/seleciona paciente em `PetRegistrationPage` OU `VeterinarioPage` . 3. Submete anamnese + carrega PDFs de exames (`pet-exam-uploader` parseia via `parse-pet-exam-pdf`). 4. Visualiza Painel Clínico (`PetClinicalAnalysisSnapshot`) com 6 estágios renderizados em paralelo. 5. Recebe stack ≤ 8 compostos com justificativa + Patient Subgraph clicável. 6. Aceita / modifica / rejeita stack (`vet-recommendation-stack-management`); decisões vão para `recommendation_logs` . 7. Emite Treatment Proposal bilingue (`treatment_proposals` , charts + cronograma + preço).

14. Jornada prevista do revisor (roadmap)

- **P0**: módulo de Real-World Outcome capture (acompanhamento longitudinal estruturado pós-prescrição).
- **P1**: módulo formal de Continuing Education AVMA-compliant.
- **P2**: alertas push para revisão periódica (3/6/12 m).
- **P3**: assinatura digital qualificada da Treatment Proposal.


15. Jornada real do estudo científico

1. Admin sobe PDF em `ScientificStudiesUploadTab` → dedup SHA-256/Levenshtein.
2. `parse-study` extrai texto + metadados → `scientific_studies` .
3. `vectorize-study` materializa 1.342 chunks (snapshot).
4. `extract-study-entities` (Stage 1) → `study_extractions` .
5. `generate-triplets` (Stage 2) → `triplet_extractions` (4.785 snapshot).
6. Auto-approve se confidence $\geq 0,50$; senão fila de curadoria humana.
7. `sync-approved-triplets` espelha em `hierarchical_edges` (38.643) e Neo4j.

16. Jornada prevista do estudo (roadmap)

- **P0**: vetorização retroativa dos 15 estudos legados sem embeddings.
- **P1**: integração nativa com Europe PMC + bioRxiv (hoje só PubMed via gap-fill).
- **P2**: extração de figuras (charts/diagramas) via VLM.
- **P3**: cross-validation automática contra dataset MedQA.

17. Comparação MedGraphRAG × VetGraphRAG v2 × Senex AI v5.1.0



Comparação MedGraphRAG × Senex

Figura 7 – Maturidade comparada em 7 dimensões. Senex AI v5.1.0 lidera em todas, com destaque para bilinguismo e no-mock policy.

Dimensão	MedGraphRAG	VetGraphRAG v2	Senex AI v5.1.0
Domínio clínico	Medicina humana ampla	Veterinária canina	Veterinária canina geroprotetora
Curadoria humana	Opcional	Recomendada	Obrigatória (gatekeeper)
Bilingue PT/EN	Não	Parcial	Em todas as camadas + I18N_VERSION

Dimensão	MedGraphRAG	VetGraphRAG v2	Senex AI v5.1.0
Digital Twin	Ausente	Sigmoidal simples	Gompertz por raça + years_gained
Gap-fill automático	Ausente	Manual	PubMed + Gemini disparado por Twin
No-mock policy	N/A	Recomendada	Estrita (rastreabilidade total)
Trigger regulatório	Ausente	Parcial	17 entradas FDA/EMA/AVMA/GMLP
Auditabilidade	Logs básicos	study_audit_logs	+ ai_task_invocations + 4 painéis

18. Conformidade FDA – matriz ponto-a-ponto

Mapeamento contra **FDA Draft Guidance Jan/2025** — Considerations for the Use of Artificial Intelligence to Support Regulatory Decision-Making for Drug and Biological Products⁹.

Requisito FDA	Status Senex	Evidência
§IV.A — Risk-based credibility framework	Atende	core_rules (18) + core_rule_audit_log
§IV.B — Model description	Atende	ai_prompt_versions versionado por (task, model)
§IV.C — Data management	Atende	Dedup SHA-256, Levenshtein, study_audit_logs
§V — Performance assessment	Parcial	Métrica years_gained projetada; falta RWPM
§VI — Lifecycle maintenance plan	Parcial	CHANGELOG + I18N_VERSION; PCCP não

Requisito FDA	Status Senex	Evidência
		formalizado
§VII — Real-World Performance Monitoring	Gap P0	Não implementado — roadmap P0
§VIII — Transparency	Atende	Patient Subgraph + transparência clínica obrigatória

Cobertura: 5/7 atende, 2/7 parcial, 0/7 não-atende.

19. Conformidade EMA + EU AI Act

Mapeamento contra EMA Reflection Paper on AI (Set/2024)^{[10](#)} e EU AI Act (Reg. 2024/1689)^{[11](#)}.

Requisito	Status	Evidência
EMA §3 — Data quality & provenance	Atende	Provenance triplet → estudo → chunk
EMA §4 — Bias detection	Parcial	<code>evidence_conflicts</code> ativo; falta análise demográfica formal
EU AI Act Art. 14 — Human oversight	Atende	Curadoria obrigatória + cap 8 + transparência
EU AI Act Art. 13 — Transparency to deployer	Atende	UI mostra origem de cada recomendação

Cobertura: 3/4 atende, 1/4 parcial.

20. Conformidade AVMA / AAVSB

Mapeamento contra AVMA Framework on AI in Veterinary Medicine (Nov/2025)^{[12](#)} e AAVSB Position Statement (2025)^{[13](#)}.

Requisito	Status	Evidência
AVMA §2 — VCPR maintenance	Atende	Recomendação é decision support , nunca prescrição autônoma
AVMA §3.2 — Species validation	Gap P0	KG não bloqueia tecnicamente extrapolação inter-espécie
AVMA §6 — Continuing Education	Gap P1	Sem módulo formal CE
AAVSB — Veterinarian-in-the-loop	Atende	Toda Treatment Proposal exige assinatura vet

Cobertura: 2/4 atende, 0/4 parcial, 2/4 gap.

21. GMLP — análise por princípio

Mapeamento contra os **10 Guiding Principles for Good Machine Learning Practice** (FDA/HC/MHRA, 2021)^{[14](#)}.

Princípio GMLP	Status	Nota
1. Multi-disciplinary expertise	Atende	Vet + dev + curador
2. Good software & security practices	Atende	RLS, has_role, GRANT explícito
3. Clinical study participants representative	Parcial	81 raças; faltam algumas minoritárias
4. Training vs test data separation	Atende	LLM não-treinada com dados clínicos
5. Selected reference standard	Atende	SNOMED-VetSCT + UMLS

Princípio GMLP	Status	Nota
6. Model design tailored to clinical workflow	Atende	Tabbed Clinical Analysis + Patient Subgraph
7. Focus on performance of human-AI team	Atende	HITL + cap 8 + auditoria
8. Testing demonstrates real-world conditions	Parcial	Demo pets cobrem 5 perfis; falta validação longitudinal
9. Users provided clear info	Atende	Transparência clínica + Subgraph
10. Deployed models monitored	Parcial	<code>ai_task_invocations</code> ativo; falta RWPM clínico

Cobertura: 7/10 atende, 3/10 parcial.

22. Pontos fortes (18)

Cada item lista a evidência (arquivo/tabela/função) que o sustenta — auditável.

- No-mock policy estrita** — `.lovable/memory/principles/curation-gatekeeper-for-vetgraphrag.md`
- Bilinguismo PT/EN em todas as camadas** — `src/i18n.ts` + colunas `*_en` em DB + dados estáticos `_en`
- Versionamento I18N_VERSION para cache-bust** — `src/i18n.ts` snapshot 1.86.7
- RLS em 97 tabelas com `has_role()` security-definer** — `public.has_role()` function
- Auditabilidade tripla:** `study_audit_logs` + `ai_task_invocations` + 4 painéis log UI
- Curadoria gatekeeper antes do KG** — trigger `reset_neo4j_sync_on_status_change`
- Pipeline determinístico 7 estágios** — `processed_studies.status` rastreia cada um
- Dedup SHA-256 + Levenshtein** — `pet-exam-uploader` + `parse-study`
- Patient Knowledge Subgraph determinístico** — `usePetClinicalAnalysisSnapshot`

- 10. **Cap rígido 8 compostos com dedupe alfanumérico** — `hybrid-recommendation`
- 11. **Taxonomias autoritativas SNOMED-VetSCT + UMLS** — `taxonomy_dictionaries` (8 ativos)
- 12. **Roteador IA universal** `ai-task-router` — governança completa (modelo + prompt + log)
- 13. **Prompts versionados** `ai_prompt_versions` — 8 ativos, ativação via RPC `security-definer`
- 14. **Gap-fill automático PubMed + Gemini** — `kg-evidence-gap-fill` disparado por Digital Twin
- 15. **Digital Twin Gompertz por raça** — 53/81 raças calibradas
- 16. **Transparência clínica obrigatória** — UI flaga recomendações sem suporte raw no grafo
- 17. **Soft-delete + DELETE-typed para bulk** — `safe-deletion-and-audit-system`
- 18. **Changelog como working memory** — `.lovable/CONTEXT.md` auto-gerado + `npm run sync:changelog`

23. Pontos fracos, gaps e riscos (12 + 5)

23.1 Gaps (12)

#	Gap	Prioridade	Mitigação proposta
1	Sem Real-World Performance Monitoring longitudinal	P0	Tabela <code>clinical_outcomes</code> + cron mensal
2	Base L1-L3 parcialmente extraída automaticamente	P0	Curadoria manual focada via <code>base_knowledge_candidates</code>
3	KG não bloqueia extrapolação inter-espécie	P0	Validação <code>species_constraint</code> em <code>triplet_extractions</code>
4	PCCP não formalizado em documento	P0	Document SOP + assinatura digital

#	Gap	Prioridade	Mitigação proposta
5	15 estudos legados sem embeddings	P1	Cron <code>vectorize-study</code> em backlog
6	Sem módulo CE AVMA-compliant	P1	Tab admin Continuing Education
7	28/81 raças sem Gompertz calibrada	P1	Importar curvas de Bonnett et al. 2020
8	Bias demográfico não auditado formalmente	P1	Notebook trimestral de fairness
9	Sem alerta push de revisão periódica	P2	Edge <code>notify-vet-review</code> + email
10	Sem integração Europe PMC / bioRxiv	P2	Estender <code>search-scientific-studies</code>
11	Sem extração de figuras (VLM)	P3	Gemini Pro Vision Stage 1.5
12	Sem cross-validation MedQA	P3	Eval suite dedicada

23.2 Riscos (5)

#	Risco	Severidade	Controle existente
1	Triplet incorreto aprovado por confidence $\geq 0,50$ sem revisão	ALTA	Limiar conservador + revisão amostral mensal
2	Recomendação extrapolada de espécie não-canina	ALTA	Escopo declarado + gap #3 em P0

#	Risco	Severidade	Controle existente
3	Drift de modelo LLM sem detecção	MÉDIA	ai_task_invocations permite eval retroativa
4	Custo IA acima do orçado em pico de uso	MÉDIA	COST_PER_1K no router + alerta admin
5	RLS bypass por edge function com service_role	BAIXA	Code review + lint supabase--linter

24. Roadmap P0-P3 detalhado

P0 – Bloqueia pleito regulatório formal (8-12 semanas): - Implementar clinical_outcomes + cron RWPM (gap #1) - Curadoria manual L1-L3 (gap #2) — meta: 95% manual - Validação species_constraint em triplets (gap #3) - Documentar PCCP (gap #4) + revisão jurídica

P1 – Maturidade clínica e regulatória (12-24 semanas): - Vetorização retroativa (gap #5) - Módulo CE (gap #6) - Calibração Gompertz completa 81 raças (gap #7) - Auditoria de bias trimestral (gap #8)

P2 – Expansão funcional (24-36 semanas): - Alertas push de revisão (gap #9) - Integração Europe PMC / bioRxiv (gap #10)

P3 – Pesquisa & inovação (36+ semanas): - VLM Stage 1.5 (gap #11) - Cross-validation MedQA (gap #12)

25. Apêndice A – Schema SQL principal (DDL real, abreviado)

```
-- user_roles (separado de profiles – anti-recursão de RLS)
CREATE TYPE public AS ('admin' 'vet' 'tutor' 'user'
CREATE TABLE public
id PRIMARY KEY DEFAULT
```

```

REFERENCES public id ON DELETE CASCADE NOT NULL
role NOT NULL
UNIQUE role
GRANT SELECT ON public TO authenticated
GRANT ALL ON public TO
ALTER TABLE public ENABLE ROW LEVEL
CREATE FUNCTION public
boolean DEFINER SET = public
AS SELECT EXISTS SELECT 1 FROM public WHERE = AND role=
-- triplet_extractions (curadoria gatekeeper)
CREATE TABLE public
id PRIMARY KEY DEFAULT
REFERENCES public id
NOT NULL NOT NULL NOT NULL
numeric numeric
DEFAULT 'pending' -- pending|approved|rejected
boolean DEFAULT false
DEFAULT DEFAULT
-- hierarchical_edges (KG materializado)
CREATE TABLE public
id PRIMARY KEY DEFAULT
NOT NULL NOT NULL
NOT NULL NOT NULL
numeric integer DEFAULT 0
REFERENCES public id
-- ai_prompt_versions (governança IA)
CREATE TABLE public
id PRIMARY KEY DEFAULT
NOT NULL
boolean DEFAULT false
DEFAULT DEFAULT

```

26. Apêndice B – Inventário de Edge Functions (67 deployadas)

Listagem real de `supabase/functions/` em 31/05/2026, agrupada por domínio:

Pipeline de estudos (10): `parse-study`, `vectorize-study`, `extract-study-entities`, `generate-triplets`, `enrich-triplet`, `enrichment-qa-sample`, `process-study`, `sync-approved-triplets`, `sync-study-to-neo4j`, `auto-tag-studies`

KG / Ontologia (9): `consolidate-knowledge-graph` , `enrich-knowledge-graph` , `import-canonical-ids` , `kg-evidence-gap-fill` , `kg-missing-triplets` , `neo4j-sync` , `sync-ontology-to-neo4j` , `classify-entity` , `relations-auditor`

RAG / Chat (6): `chat` , `chat-meta-study` , `document-chat` , `graph-rag-search` , `gemini-file-search` , `test-rag-similarity`

Clínico / Recomendação (10): `extract-pet-clinical-data` , `parse-pet-exam-pdf` , `condition-insights` , `check-insight-originality` , `hybrid-recommendation` , `calculate-recommendation-confidence` , `project-pet-trajectory` , `evaluate-meta-study-reliability` , `extract-meta-study` , `generate-meta-study-cover`

Coortes / Análise populacional (7): `analyze-all-cohorts-patterns` , `analyze-cohort-patterns` , `check-cohort-originality` , `finalize-stalled-cohort` , `generate-synthetic-cohort` , `suggest-cohort-ideas` , `migrate-nutraceutical-conditions`

Governança IA (7): `ai-config` , `ai-task-healthcheck` , `ai-task-test` , `api-usage-stats` , `provider-health` , `sync-system-prompts` , `backfill-triplet-enrichment`

Tradução & i18n (4): `translate-text` , `translate-conditions` , `translate-and-categorize-conditions` , `run-translation-audit`

Catálogos & enrich externo (10): `bulk-enrich-pet-food` , `enrich-pet-food-product` , `process-nutraceutical-spreadsheet` , `web-dosage-lookup` , `fetch-external-ontologies` , `search-scientific-studies` , `download-study-pdf` , `perplexity-health` , `query-perplexity` , `suggest-taxonomy-terms`

Outros (4): `admin-create-user` , `invoxia-api` , `batch-reprocess-triplets` , `run-migrations`

Todas operam com `verify_jwt=false` + validação JWT em código (signing-keys system).

27. Apêndice C – Prompts e modelos LLM (snapshot 8 ativos)


Snapshot de `ai_prompt_versions` WHERE `is_active=true` em 31/05/2026:

task_id	model_id	reasoning_effort
<code>extract_entities</code>	<code>google/gemini-2.5-flash</code>	low
<code>generate_triplets</code>	<code>google/gemini-2.5-pro</code>	medium

task_id	model_id	reasoning_effort
enrich_triplet	google/gemini-2.5-flash	low
classify_entity	google/gemini-2.5-flash-lite	minimal
chat_clinical	google/gemini-3-flash-preview	medium
gap_fill	openai/gpt-5-mini	medium
relations_auditor	google/gemini-2.5-pro	high
digital_twin_project	google/gemini-2.5-flash	low

Ativação via `activate_ai_prompt_version(uuid)` (security-definer, admin-only). Trigger `ai_prompt_versions_enforce_single_active` garante atomicidade (apenas 1 ativo por par `task_id` x `model_id`).

28. Apêndice D – Métricas operacionais (snapshot 31/05/2026)



Métricas de sistema

Figura 8 – Snapshot quantitativo do estado atual da plataforma Senex AI.

Domínio	Métrica	Valor
Estudos	Catalogados	13

Domínio	Métrica	Valor
	Processados (pipeline completo)	59
	Vetorizados (distinct)	44
	Chunks vetoriais	1.342
	Meta-estudos	6
Knowledge Graph	Triplets extraídos	4.785
	Triplets aprovados	3.924
	Triplets sincronizados	4.411
	Arestas hierárquicas	38.643
	Nós ontologia veterinária	941
Conhecimento clínico	Condições curadas	191
	Nutracêuticos	30
	Drug substances	50
	Predisposições raciais	254 (81 raças)
	Lab reference ranges	31
	Compound dosage reference	58
Core rules & taxonomy	Core rules	18
	Taxonomy dictionaries ativos	8
Pacientes	Perfis totais	668
	Demo (is_demo=true)	5
Governança IA	Prompts versionados	8 (8 ativos)
	Invocações auditadas	28
Auditoria	Requests	3 (1 pendente)
	Audits gerados	2 (v3, v5.1.0)
Acesso	User roles	6
Infraestrutura	Edge Functions deployadas	67
	Tabelas public	97

Domínio	Métrica	Valor
	I18N_VERSION	1.86.7

29. Bibliografia (rodapés [1]-[14])

Auditoria gerada em 31 de maio de 2026 por Lovable Agent · Equipe PetMoreTime · Senex AI v5.1.0 · Auto-auditoria first-party · Recomenda-se auditoria independente de terceiros como item P1 antes de pleito regulatório formal.

1. Wu et al., **MedGraphRAG: Towards Safe Medical Large Language Model via Graph Retrieval-Augmented Generation**, Oxford 2024. [arXiv:2408.04187](#)
2. Edge et al., **From Local to Global: A Graph RAG Approach to Query-Focused Summarization**, Microsoft Research 2024. [arXiv:2404.16130](#)
3. U.S. FDA, **Draft Guidance: Considerations for the Use of Artificial Intelligence to Support Regulatory Decision-Making for Drug and Biological Products**, Jan/2025.
4. European Medicines Agency, **Reflection Paper on the use of AI in the medicinal product lifecycle**, Set/2024.
5. European Union, **Regulation (EU) 2024/1689 (AI Act)**, OJ L, 12 Jul 2024.
6. AVMA, **Framework on AI in Veterinary Medicine**, Nov/2025.
7. FDA/Health Canada/MHRA, **Good Machine Learning Practice – 10 Guiding Principles**, 2021.
8. AAVSB, **Position Statement on AI in Veterinary Practice**, 2025.
9. U.S. FDA, **Draft Guidance: Considerations for the Use of Artificial Intelligence to Support Regulatory Decision-Making**

for Drug and Biological Products, Jan/2025.[↵](#)

10. European Medicines Agency, **Reflection Paper on the use of AI in the medicinal product lifecycle**, Set/2024.[↵](#)
11. European Union, **Regulation (EU) 2024/1689 (AI Act)**, OJ L, 12 Jul 2024.[↵](#)
12. AVMA, **Framework on AI in Veterinary Medicine**, Nov/2025.[↵](#)
13. AAVSB, **Position Statement on AI in Veterinary Practice**, 2025.[↵](#)
14. FDA/Health Canada/MHRA, **Good Machine Learning Practice – 10 Guiding Principles**, 2021.[↵](#)